

Pronóstico de Ventas para Walmart

Proyectos estadísticos

Prof. Francisco Alfaro

Helena Bahamondes

Carlos Tapia

Mateo Hidalgo

Brian Valenzuela

Universidad Técnica Federico Santa María

Martes 2 de Diciembre 2025



1 Introducción

- Problema
- Datos

2 Modelos y análisis

3 Resultados

4 Conclusión

- Limitaciones
- Trabajo a futuro

Problema

- Trabajaremos con datos provenientes de Walmart.
- Nuestro objetivo es predecir ventas futuras (28 días).



Datos

• sales_train_validation.csv:

	id	item_id	dept_id	cat_id	store_id	state_id	d_1	d_2	d_3	d_4	...	d_1904	d_1905	d_1906	d_1907	d_1908	d_1909	d_1910	d_1911	d_1912	d_1913
HOBBIES_1_001_CA_1_validation	HOBBIES_1_001	HOBBIES_1	HOBBIES	CA_1	CA	CA	0	0	0	0	...	1	3	0	1	1	1	3	0	1	1
HOBBIES_1_001_CA_2_validation	HOBBIES_1_001	HOBBIES_1	HOBBIES	CA_2	CA	CA	0	0	0	0	...	0	0	1	2	0	4	0	0	2	2
HOBBIES_1_001_CA_3_validation	HOBBIES_1_001	HOBBIES_1	HOBBIES	CA_3	CA	CA	0	0	0	0	...	0	2	4	0	1	1	1	0	3	3
HOBBIES_1_001_CA_4_validation	HOBBIES_1_001	HOBBIES_1	HOBBIES	CA_4	CA	CA	0	0	0	0	...	1	0	0	1	0	1	0	1	2	1
HOBBIES_1_001_TX_1_validation	HOBBIES_1_001	HOBBIES_1	HOBBIES	TX_1	TX	TX	0	0	0	0	...	0	0	0	0	1	0	1	0	0	2
HOBBIES_1_001_TX_2_validation	HOBBIES_1_001	HOBBIES_1	HOBBIES	TX_2	TX	TX	0	0	0	0	...	0	0	0	0	0	1	0	0	0	0
HOBBIES_1_001_TX_3_validation	HOBBIES_1_001	HOBBIES_1	HOBBIES	TX_3	TX	TX	0	0	0	0	...	0	3	0	0	0	0	0	0	0	0
HOBBIES_1_001_WI_1_validation	HOBBIES_1_001	HOBBIES_1	HOBBIES	WI_1	WI	WI	0	0	0	0	...	0	0	0	0	0	0	1	2	1	1
HOBBIES_1_001_WI_2_validation	HOBBIES_1_001	HOBBIES_1	HOBBIES	WI_2	WI	WI	0	0	0	0	...	1	1	0	0	0	0	0	0	0	1
HOBBIES_1_001_WI_3_validation	HOBBIES_1_001	HOBBIES_1	HOBBIES	WI_3	WI	WI	0	0	0	0	...	0	1	0	0	0	0	0	0	0	0


• calendar.csv:

date	wm_yr_wk	weekday	wday	month	year	d	event_name_1	event_type_1	event_name_2	event_type_2	snap_CA	snap_TX	snap_WI
2011-01-29	11101	Saturday	1	1	2011	d_1	NaN	NaN	NaN	NaN	0	0	0
2011-01-30	11101	Sunday	2	1	2011	d_2	NaN	NaN	NaN	NaN	0	0	0
2011-01-31	11101	Monday	3	1	2011	d_3	NaN	NaN	NaN	NaN	0	0	0
2011-02-01	11101	Tuesday	4	2	2011	d_4	NaN	NaN	NaN	NaN	1	1	0
2011-02-02	11101	Wednesday	5	2	2011	d_5	NaN	NaN	NaN	NaN	1	0	1

• sell_prices.csv:

store_id	item_id	wm_yr_wk	sell_price
CA_1	HOBBIES_1_001	11325	9.58
CA_1	HOBBIES_1_001	11326	9.58
CA_1	HOBBIES_1_001	11327	8.26
CA_1	HOBBIES_1_001	11328	8.26
CA_1	HOBBIES_1_001	11329	8.26


EDA





- 3049 productos distribuidos en todas las tiendas.
- 1969 días de registros de venta.



- Sólo tenemos datos faltantes en el archivo 'calendar.csv'.
- En un 68.20 % de los días no se presentan ventas.
- Hay 162 eventos registrados.





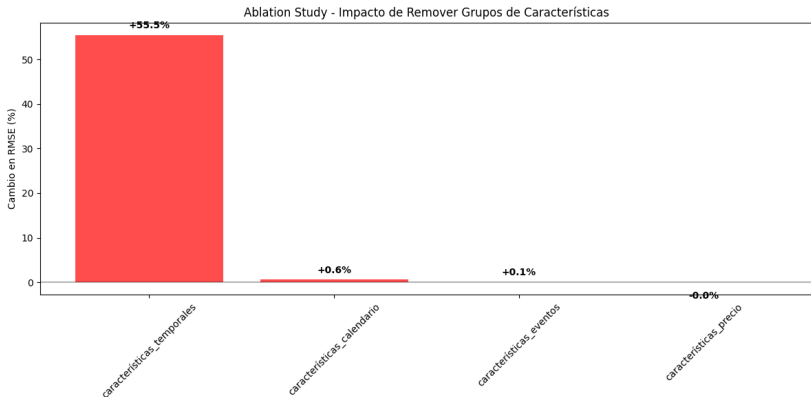


- 1 Introducción
 - Problema
 - Datos
- 2 Modelos y análisis
- 3 Resultados
- 4 Conclusión
 - Limitaciones
 - Trabajo a futuro

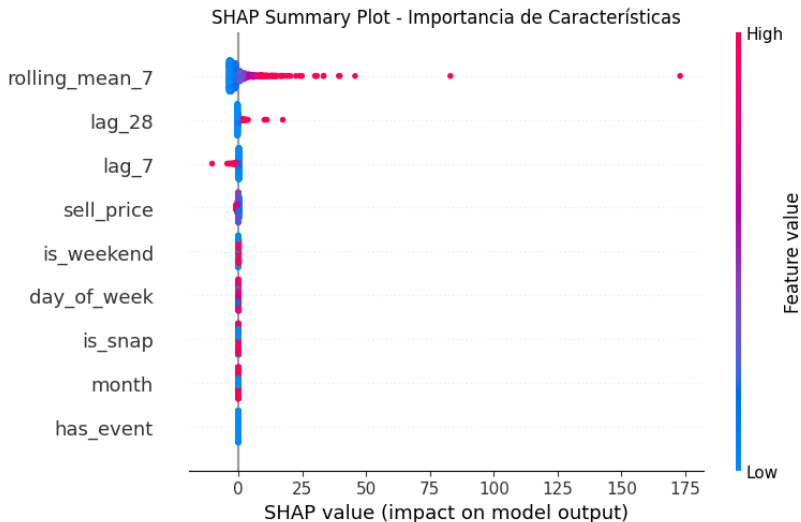
Modelos

- 1) Naive Estacional
- 2) Random Forest
- 3) LightGBM
- 4) Ridge
- 5) ARIMA
- 6) SARIMA
- 7) Suavizamiento Exponencial (ETS)

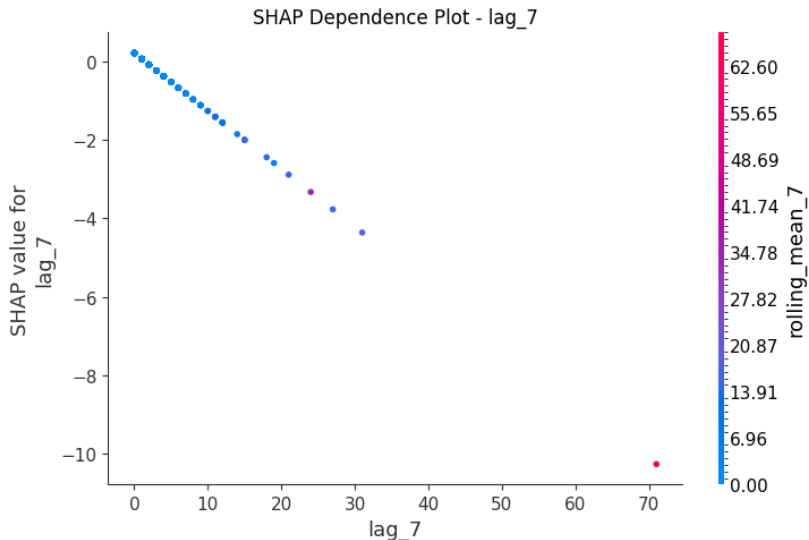
Impacto de características



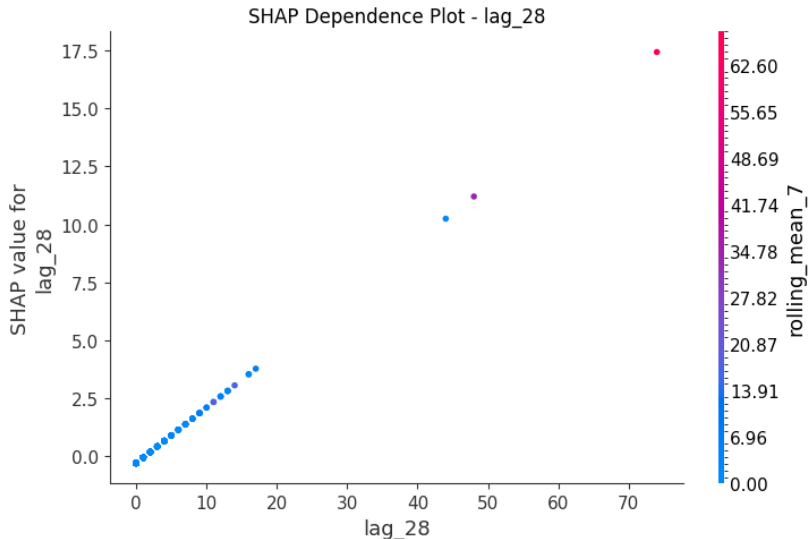
Grados de características



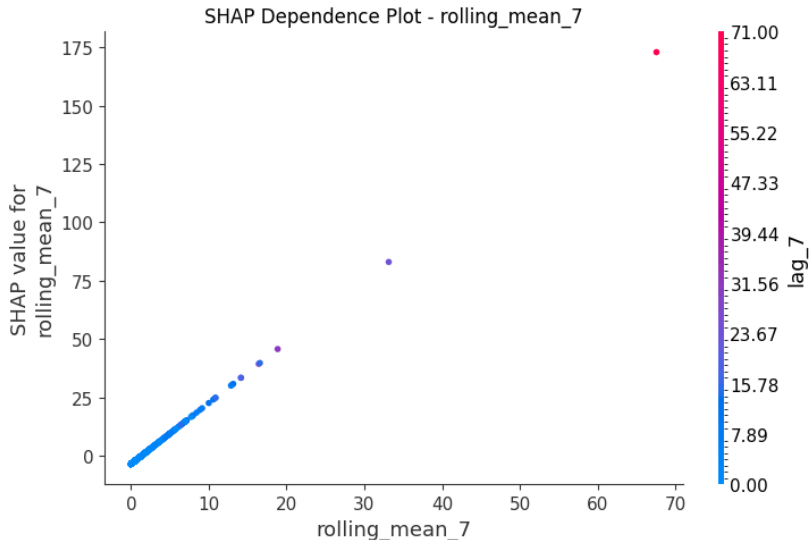
Impacto ventas a 7 días



Impacto ventas a 28 días




Impacto media móvil a 7 días






- 1 Introducción
 - Problema
 - Datos
- 2 Modelos y análisis
- 3 Resultados
- 4 Conclusión
 - Limitaciones
 - Trabajo a futuro

Modelos ML

- Alrededor de 91.000 observaciones (40 % de los datos).
- 57 % son ceros.




Análisis Ridge




Comparación con Series de Tiempo

- Uso de 20 y 50 series muestreadas.
- Intermitentes (muchos ceros), estables y mixtas ($\approx 50\%$ ceros)



Comparación final



- 11 Intermitentes, 9 Mixtas y 3 Estables.

Parámetros ARIMA

(p,q,d)	Número de victorias	Porcentaje
(0, 0, 0)	14	(60.9 %)
(0, 0, 1)	2	(8.7 %)
(1, 0, 1)	2	(8.7 %)
(0, 1, 1)	1	(4.3 %)
(3, 1, 2)	1	(4.3 %)
(1, 1, 2)	1	(4.3 %)
(4, 0, 1)	1	(4.3 %)
(3, 0, 2)	1	(4.3 %)

Cuadro: Parámetros obtenidos para modelo ARIMA

- 1 Introducción
 - Problema
 - Datos
- 2 Modelos y análisis
- 3 Resultados
- 4 Conclusión
 - Limitaciones
 - Trabajo a futuro

Limitaciones

- Muchos datos y poca capacidad computacional.
- Serie muy estacional, lo que no se refleja con modelos ARIMA.
- Datos faltantes en calendario.

Trabajo a futuro

- Definir eventos como temporadas en lugar de días.
- Incluir promociones, niveles de inventario, información de competidores.

Conclusión

- El mejor desempeño correspondió a modelos ARIMA, donde la configuración (0,0,0) obtuvo la mayoría de las victorias en las series muestreadas.
- El problema es altamente intermitente y heterogéneo (\approx 57–68 % ceros por serie), por lo que los modelos ML (p. ej. Ridge/LightGBM) siguen siendo útiles cuando hay patrones marcados y variables externas.

Muchas Gracias